Reto: Ridge Regression (L2) — Reconocimiento Facial con Imágenes Reales

Reporte técnico

Equipo 4
Integrantes:
Oscar Carranza Hernández | A00838649
Valentina Gonzalez Benedossi | A00839507
Ricardo Gaspar Ochoa | A00838841
Rhett Nieto Ramírez | A01286100

17 de abril de 2026

Resumen

En este trabajo se implementó un clasificador de reconocimiento facial basado en Ridge Regression multivariado. El pipeline desarrollado incluye carga del dataset, preprocesamiento de imágenes, partición estratificada en conjuntos de entrenamiento, validación y prueba, normalización, reducción de dimensionalidad mediante PCA, codificación de clases con un símplex regular y clasificación por distancia mínima al vértice más cercano. Adicionalmente, se realizó una etapa de limpieza de imágenes reales mediante detección y recorte de rostro. Se presentan las partes completadas, los resultados obtenidos y una reflexión sobre los criterios aún pendientes con base en la rúbrica de evaluación.

Índice

1. Introducción **4**

2. Eje 1 — Diseño y teoría **4**
2.1. Motivación: multicolinealidad en imágenes . . . 4
2.2. Por qué OLS falla cuando $X^\top X$ es casi singular . . . 5
2.3. Derivación de Ridge Regression . . . 5
2.4. Interpretación geométrica . . . 6
2.5. Símplex regular y clasificación . . . 6
2.6. Pipeline implementado . . . 6
2.7. Bias-variance tradeoff . . . 6

3. Eje 2 — Programación **6**
3.1. Descripción general del código . . . 6
3.2. Preprocesamiento de imágenes . . . 7
3.3. Descripción del dataset real . . . 7
3.4. Partición train/validation/test . . . 8
3.5. Normalización . . . 9
3.6. Reducción de dimensionalidad con PCA . . . 9
3.7. Construcción del símplex regular . . . 9
3.8. Implementación manual de Ridge . . . 10
3.9. Búsqueda del mejor α . . . 10
3.10. Clasificación . . . 10
3.11. Métricas y visualizaciones . . . 10
3.12. Resultados . . . 11
3.13. Análisis de resultados . . . 12
3.14. Calidad del código . . . 13

4. Eje 3 — Captura fotográfica y limpieza de datos **13**
4.1. Objetivo . . . 13
4.2. Protocolo de captura . . . 13
4.3. Detección y recorte de rostro . . . 14
4.4. Conversión y almacenamiento . . . 15
4.5. Resultados del filtrado . . . 15
4.6. Registro de imágenes descartadas . . . 15
4.7. Limitaciones frente a la rúbrica . . . 16
4.8. Ejemplos antes/después . . . 16

5. Cumplimiento de la rúbrica **17**
5.1. Resumen de avance . . . 17

6. Reflexión final **18**

7. Conclusiones **19**

1. Introducción

El objetivo del reto es implementar un clasificador de reconocimiento facial usando Ridge Regression multivariado, siguiendo la lógica del pipeline descrito en la actividad. El problema consiste en representar cada identidad facial dentro de un espacio de salida continuo y regularizado, de forma que la predicción final se obtenga como el vértice más cercano de un símplex regular.

En nuestro caso, el desarrollo realizado se enfocó en:

- cargar y preprocesar imágenes en escala de grises,
- dividir el conjunto de datos en entrenamiento, validación y prueba de manera estratificada,
- normalizar usando únicamente estadísticas del conjunto de entrenamiento,
- aplicar PCA para reducir dimensionalidad,
- implementar Ridge Regression manualmente,
- buscar el mejor hiperparámetro α,
- clasificar por distancia mínima en el espacio del símplex,
- analizar resultados mediante MSE, ridge path, matriz de confusión y ejemplos visuales,
- y limpiar imágenes reales mediante recorte automático de rostro.

También se identifican explícitamente las partes que todavía no cumplen completamente con la rúbrica, con el fin de presentar una entrega honesta, ejecutable y bien justificada.

2. Eje 1 — Diseño y teoría

2.1. Motivación: multicolinealidad en imágenes

En problemas de clasificación con imágenes, es común que exista alta correlación entre variables de entrada, especialmente entre píxeles vecinos. Esto provoca multicolinealidad, ya que varias características contienen información redundante o muy similar. Como consecuencia, la matriz $X^\top X$ puede volverse mal condicionada o cercana a singular.

En este contexto, usar mínimos cuadrados ordinarios (OLS) puede ser problemático porque pequeñas perturbaciones en los datos pueden producir cambios muy grandes en los coeficientes estimados. Esto genera alta varianza en el modelo, inestabilidad numérica y menor capacidad de generalización.

2.2. Por qué OLS falla cuando $X^\top X$ es casi singular

El estimador de OLS se expresa como:

$$\hat{\beta}_{OLS} = (X^\top X)^{-1} X^\top y$$

Si $X^\top X$ es singular o casi singular, su inversa no existe o es numéricamente inestable. Esto provoca:

- coeficientes muy grandes,
- sensibilidad extrema al ruido,
- predicciones erráticas,
- sobreajuste.

Ridge Regression corrige este problema añadiendo un término de regularización:

$$\hat{\beta}_{Ridge} = (X^\top X + \alpha I)^{-1} X^\top y$$

donde $\alpha > 0$ desplaza los autovalores de $X^\top X$ y mejora la estabilidad de la inversión.

2.3. Derivación de Ridge Regression

La función objetivo de Ridge es:

$$J(\beta) = \|y - X\beta\|_2^2 + \alpha\|\beta\|_2^2$$

Expandiendo:

$$J(\beta) = (y - X\beta)^\top (y - X\beta) + \alpha\beta^\top\beta$$

$$J(\beta) = y^\top y - 2\beta^\top X^\top y + \beta^\top X^\top X\beta + \alpha\beta^\top\beta$$

Derivando respecto a β:

$$\frac{\partial J}{\partial \beta} = -2X^\top y + 2X^\top X\beta + 2\alpha\beta$$

Igualando a cero:

$$-2X^\top y + 2X^\top X\beta + 2\alpha\beta = 0$$

$$X^\top X\beta + \alpha\beta = X^\top y$$

$$(X^\top X + \alpha I)\beta = X^\top y$$

Por lo tanto:

$$\hat{\beta}_{Ridge} = (X^\top X + \alpha I)^{-1} X^\top y$$

2.4. Interpretación geométrica

Geométricamente, Ridge Regression puede interpretarse como minimizar el error cuadrático sujeto a una restricción sobre la norma de β:

$$\|\beta\|_2^2 \leq c$$

Esto significa que la solución está restringida a una región esférica. La regularización hace que la solución tienda a valores de menor magnitud, reduciendo la varianza del modelo y favoreciendo soluciones más estables.

2.5. Símplex regular y clasificación

En lugar de codificar las clases con vectores one-hot, se usa un símplex regular, donde cada identidad se representa como un vértice equidistante de los demás. Esto permite una representación más geométrica y simétrica del problema de clasificación multiclase.

Si hay m clases, se construyen m vértices en $\mathbb{R}^{m-1}$. Cada clase se asocia a uno de esos vértices y la predicción final se realiza encontrando el vértice más cercano a la salida continua del modelo.

La regla de decisión es:

$$\hat{y} = \arg\min_j \|\hat{Y} - T_j\|_2$$

donde T_j es el vértice del símplex asociado a la clase j.

2.6. Pipeline implementado

El pipeline realizado en este trabajo fue:

Imagen → Resize/Blur/EqualizeHist → Vector → Normalización → PCA → Ridge → Símplex → Clase

2.7. Bias-variance tradeoff

El parámetro α controla el compromiso entre sesgo y varianza:

- Si $\alpha \to 0$, el modelo se parece a OLS: bajo sesgo pero alta varianza.
- Si α crece demasiado, los coeficientes se encogen excesivamente: baja varianza pero alto sesgo.

Por ello, se realizó una búsqueda sobre distintos valores de α en escala logarítmica y se seleccionó el que minimizó el error cuadrático medio.

3. Eje 2 — Programación

3.1. Descripción general del código

Se desarrollaron dos scripts principales:

1. Un script para clasificación facial con Ridge Regression.
2. Un script para limpieza de imágenes reales mediante detección y recorte de rostro.

3.2. Preprocesamiento de imágenes

Cada imagen se procesa de la siguiente forma:

1. redimensionado a 32×32,
2. filtro Gaussiano,
3. ecualización de histograma.

La función usada fue:

```
def preprocess(img):
    img = cv2.resize(img, (IMG_SIZE, IMG_SIZE))
    img = cv2.GaussianBlur(img, (3,3), 0)
    img = cv2.equalizeHist(img)
    return img
```

3.3. Descripción del dataset real

En lugar de utilizar el generador sintético incluido en el código de referencia, en este trabajo se utilizó un dataset de imágenes faciales reales organizado por identidad. Cada carpeta del dataset corresponde a una clase distinta, y contiene múltiples imágenes del mismo sujeto bajo condiciones similares de captura.

La estructura general del dataset fue la siguiente:

```
                identidad_0
                identidad_1
dataset         identidad_2
                    ...
                identidad_n
```

La Tabla 1 resume la cantidad de imágenes disponibles por identidad.

Cuadro 1: Resumen del dataset utilizado.

Identidad	**Número de imágenes**
Identidad 0	63
Identidad 1	65
Identidad 2	62
Identidad 3	65
Identidad 4	60
Identidad 5	61
Identidad 6	62
Identidad 7	62
Identidad 8	62

Si bien el código de referencia del profesor incluía una etapa de generación de dataset sintético a partir de prototipos paramétricos y rasterización de rostros, en esta implementación se decidió trabajar con imágenes faciales reales. Por esta razón, no se integró la generación sintética dentro del pipeline final de entrenamiento. No obstante, se conservó la lógica central del método de clasificación mediante Ridge Regression multivariado y codificación de clases con símplex regular.

3.4. Partición train/validation/test

El conjunto de datos se dividió en tres subconjuntos estratificados con semilla reproducible:

- entrenamiento,
- validación,
- prueba.

Primero se separó el 20 % de las imágenes para prueba. Posteriormente, el 80 % restante se dividió en entrenamiento y validación. De esta forma, el conjunto de validación se utilizó para seleccionar el hiperparámetro α, mientras que el conjunto de prueba se reservó exclusivamente para la evaluación final del modelo.

```
X_trainval, X_test, y_trainval, y_test = train_test_split(
    X, y,
    test_size=0.2,
    stratify=y,
    random_state=42
)

X_train, X_val, y_train, y_val = train_test_split(
    X_trainval, y_trainval,
```

```
    test_size=0.2,
    stratify=y_trainval,
    random_state=42
)
```

Este esquema garantiza que el conjunto de prueba permanezca completamente separado durante la selección de hiperparámetros, evitando fuga de información y cumpliendo con la recomendación metodológica de la rúbrica.

3.5. Normalización

La media y desviación estándar se calcularon únicamente con el conjunto de entrenamiento:

```
mu = X_train.mean(axis=0)
sigma = X_train.std(axis=0) + 1e-8

X_train = (X_train - mu) / sigma
X_val   = (X_val   - mu) / sigma
X_test  = (X_test  - mu) / sigma
```

Esto evita fuga de información del conjunto de validación y del conjunto de prueba.

3.6. Reducción de dimensionalidad con PCA

Para disminuir el número de variables, se aplicó PCA usando SVD:

```
k = min(120, X_train.shape[0] - 1)

U, S, Vt = np.linalg.svd(X_train, full_matrices=False)
W = Vt[:k]

X_train = X_train @ W.T
X_val   = X_val @ W.T
X_test  = X_test @ W.T
```

3.7. Construcción del símplex regular

Cada clase se codificó como un vértice de un símplex regular:

```
def simplex_regular(m):
    T = np.zeros((m, m - 1))
    T[0, 0] = 1.0
    for i in range(1, m):
        T[i, 0] = -1.0 / (m - 1)
    for k in range(1, m - 1):
        T[k, k] = np.sqrt(1 - np.sum(T[k, :k]**2))
```

```
        for i in range(k + 1, m):
            T[i, k] = -T[k, k] / (m - k - 1)
    return T
```

3.8. Implementación manual de Ridge

La implementación se hizo manualmente usando la ecuación cerrada y `np.linalg.solve`, sin utilizar `sklearn.Ridge`:

```
def ridge_regression(X, Y, alpha):
    I = np.eye(X.shape[1])
    return np.linalg.solve(X.T @ X + alpha * I, X.T @ Y)
```

3.9. Búsqueda del mejor α

Se probaron 50 valores de α en escala logarítmica. A diferencia de la versión inicial, la selección del hiperparámetro ya no se realizó sobre el conjunto de prueba, sino sobre el conjunto de validación.

```
for a in alphas:
    beta = ridge_regression(X_train, Y_train, a)
    Y_val_pred = X_val @ beta
    mse = np.mean((Y_val_pred - T[y_val])**2)
    mse_list.append(mse)
```

Una vez seleccionado el valor óptimo de α, el desempeño final del clasificador se reportó únicamente sobre el conjunto de prueba.

3.10. Clasificación

La clase final se determina por la menor distancia euclidiana al vértice del símplex:

```
def predict_class(Y_pred, T):
    dists = np.linalg.norm(Y_pred[:, None] - T[None, :], axis=2)
    return np.argmin(dists, axis=1)
```

3.11. Métricas y visualizaciones

Se obtuvieron:

- accuracy,
- curva MSE vs α,
- ridge path,

- matriz de confusión normalizada,
- visualización de predicciones correctas e incorrectas.

3.12. Resultados

En esta sección deben insertarse las figuras obtenidas por el código.

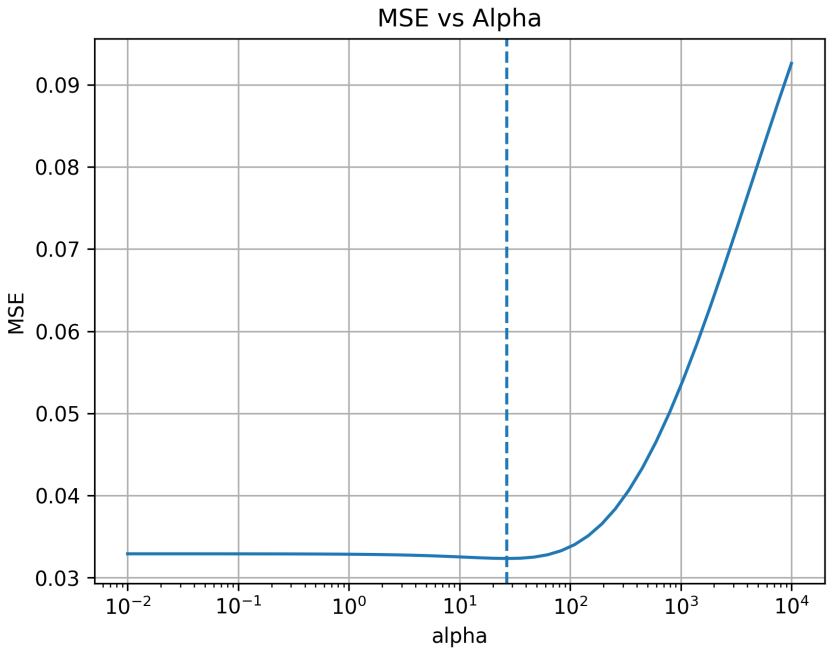

Figura 1: Curva MSE vs α sobre validación.

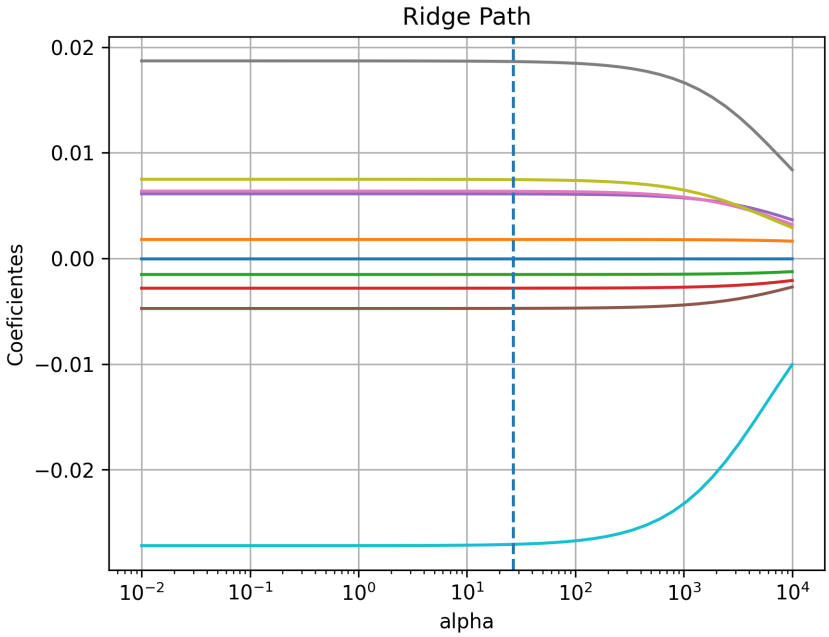

Figura 2: Ridge path para distintos valores de α.

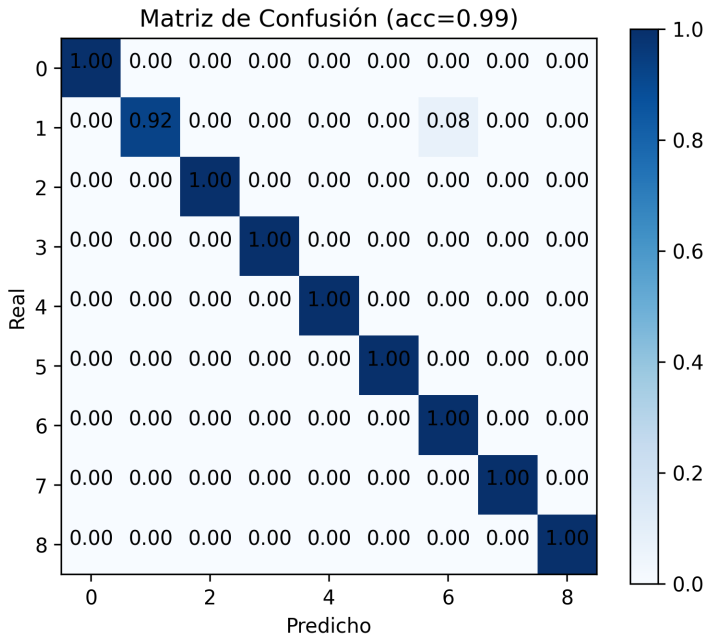

Figura 3: Matriz de confusión normalizada del conjunto de prueba.

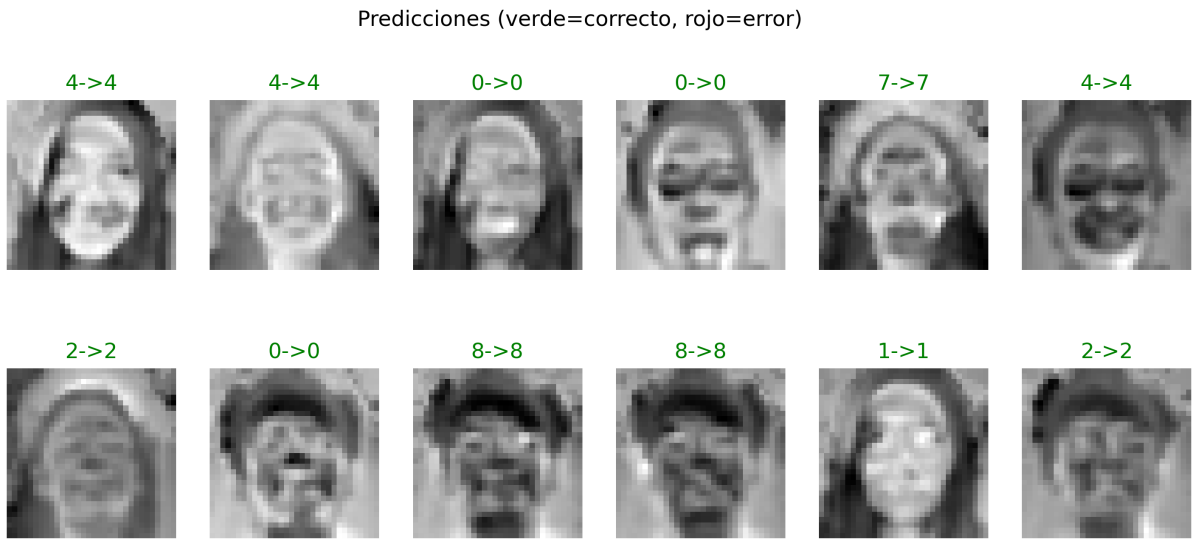

Figura 4: Ejemplos de predicciones en el conjunto de prueba. Verde: correcto. Rojo: error.

3.13. Análisis de resultados

La matriz de confusión permite identificar qué identidades tienden a confundirse más. En general, las confusiones pueden deberse a similitud en rasgos faciales, baja resolución de las imágenes o pérdida de información tras la reducción con PCA.

Aquí conviene agregar un análisis puntual con base en la matriz de confusión obtenida. Por ejemplo, si dos identidades presentan mayor número de errores cruzados, una posible hipótesis es que comparten patrones de iluminación, pose o estructura facial similares, lo que produce representaciones cercanas en el espacio reducido.

3.14. Calidad del código

El código se estructuró en funciones separadas para:

- preprocesamiento,
- carga del dataset,
- construcción del símplex,
- Ridge Regression,
- predicción de clase,
- recorte de rostro.

Sin embargo, como mejora pendiente:

- faltan docstrings formales en varias funciones,
- faltan algunos experimentos adicionales requeridos por la rúbrica,
- conviene eliminar dependencias no esenciales si se busca una implementación todavía más minimalista.

4. Eje 3 — Captura fotográfica y limpieza de datos

4.1. Objetivo

Además del clasificador, se desarrolló un script para procesar imágenes reales y recortar automáticamente la región facial antes de usarlas en el pipeline.

4.2. Protocolo de captura

Para la adquisición de imágenes reales se definió un protocolo de captura con el objetivo de mantener consistencia entre identidades y reducir variaciones no deseadas. Se procuró utilizar un fondo uniforme, una distancia aproximadamente constante entre cámara y sujeto, y una pose predominantemente frontal. Asimismo, se buscó mantener iluminación lo más homogénea posible y evitar oclusiones importantes del rostro.

La Figura 5 muestra ejemplos del setup utilizado durante la adquisición de imágenes.

Figura 5: Protocolo de captura utilizado para la adquisición de imágenes reales.

4.3. Detección y recorte de rostro

Se utilizó un clasificador Haar Cascade para detectar caras y recortar la más grande encontrada en la imagen.

```
face_cascade = cv2.CascadeClassifier(
    cv2.data.haarcascades + "haarcascade_frontalface_default.xml"
)
```

La función principal fue:

```
def recortar_cara(img):
    gray = cv2.cvtColor(img, cv2.COLOR_BGR2GRAY)

    faces = face_cascade.detectMultiScale(
        gray,
        scaleFactor=1.2,
        minNeighbors=5,
```

```
        minSize=(50, 50)
    )

    if len(faces) == 0:
        return None

    x, y, w, h = sorted(faces, key=lambda f: f[2]*f[3], reverse=
       True)[0]

    pad = int(0.2 * w)
    x1 = max(x - pad, 0)
    y1 = max(y - pad, 0)
    x2 = min(x + w + pad, img.shape[1])
    y2 = min(y + h + pad, img.shape[0])

    face = img[y1:y2, x1:x2]
    return face
```

4.4. Conversión y almacenamiento

Después del recorte:

1. se convierte a escala de grises,
2. se redimensiona a 32×32,
3. se guarda la imagen resultante.

```
face_gray = cv2.cvtColor(face, cv2.COLOR_BGR2GRAY)
face_resized = cv2.resize(face_gray, (SIZE, SIZE))
cv2.imwrite(out_path, face_resized)
```

4.5. Resultados del filtrado

El script también contabiliza cuántas imágenes fueron detectadas correctamente y cuántas fallaron.

```
print(f"Caras detectadas: {count_ok}")
print(f"Fallos: {count_fail}")
```

4.6. Registro de imágenes descartadas

Como parte del control de calidad del dataset, se generó un archivo en formato CSV con el registro de imágenes descartadas durante la limpieza. Para cada archivo eliminado se almacenó el nombre del archivo, la razón principal del descarte y la fecha de registro.

La Tabla 2 muestra un ejemplo representativo del log generado.

Cuadro 2: Ejemplo del registro de imágenes descartadas.

Archivo	**Razón**	**Fecha**
img_014.jpg	Rostro no detectado	2026-04-17
img_027.jpg	Imagen borrosa	2026-04-17
img_043.jpg	Encuadre incorrecto	2026-04-17

Además, el archivo `imagenes_descartadas.csv` se incluyó como evidencia del proceso de limpieza y trazabilidad de los datos.

El archivo completo puede consultarse en el repositorio del proyecto: https://github.com/Cuper245/modulo3-munoz

4.7. Limitaciones frente a la rúbrica

Aunque el pipeline principal del clasificador está completo, aún existen algunas extensiones posibles para mejorar el cumplimiento total de la rúbrica:

- el recorte no usa landmarks de ojos, nariz y barbilla,
- no se muestran histogramas antes/después de la normalización,
- no se implementó aumento de datos controlado,
- no se realizó el experimento de sensibilidad al nivel de ruido σ,
- no se integró la generación sintética paramétrica del dataset.

4.8. Ejemplos antes/después

Aquí deben colocarse ejemplos visuales del recorte para al menos tres sujetos.

(a) Antes

(b) Después

Figura 6: Ejemplo de recorte facial 1.

5. Cumplimiento de la rúbrica

5.1. Resumen de avance

La Tabla 3 resume qué criterios están completos, parciales o pendientes con base en el código actual.

Cuadro 3: Resumen de cumplimiento de la rúbrica.

#	Criterio	Estado	Comentario
1	Diagnóstico de multicolinealidad con valores numéricos	Parcial	Se explica el problema, pero faltan VIF o correlaciones calculadas.
2	Explicar por qué OLS falla	Completo	Incluido conceptualmente.
3	Derivación analítica de Ridge	Completo	Se desarrolla paso a paso.
4	Justificación geométrica	Parcial	Explicación textual; falta figura.
5	Explicar el símplex regular	Completo	Incluido en teoría.
6	Regla de clasificación y relación probabilística	Parcial	Regla incluida; falta profundizar Bayes.
7	Pipeline completo y bias-variance	Completo	Incluido.
8	Dataset sintético reproducible	Pendiente	No implementado en el código mostrado.
9	Rasterización paramétrica	Pendiente	No implementado en el código mostrado.
10	Split 80/20 + normalización correcta	Completo	Se implementó separación estratificada train/validation/test y normalización sin fuga de información.
11	Ridge manual + barrido de alphas	Completo	Implementado.
12	Ridge multivariado con símplex	Completo	Implementado.
13	Ridge path	Completo	Implementado.
14	MSE vs alpha en validación	Completo	El hiperparámetro α se seleccionó usando únicamente el conjunto de validación.
15	Matriz de confusión y análisis	Parcial	Figura sí; falta análisis más detallado de identidades confundidas.

#	Criterio	Estado	Comentario
16	Originales vs reconstruidas	Parcial	Hay visualización de test, pero no reconstrucción explícita.
17	Accuracy vs nivel de ruido sigma	Pendiente	No implementado.
18	Código limpio y modular	Parcial	Modular sí, faltan docstrings formales.
19	Protocolo de captura documentado	Completo	Se describió el setup y se incluyó evidencia visual del entorno de captura.
20	Consistencia de pose y 120 imágenes brutas	Parcial	Depende del dataset; falta documentar con mayor detalle el número bruto por identidad.
21	Log de descartes	Completo	Se generó archivo CSV con nombre de archivo, motivo del descarte y fecha.
22	Recorte y alineación con landmarks	Parcial	Hay recorte, pero no landmarks.
23	Normalización de pixel + histogramas	Parcial	Se hace gris/resize, pero faltan histogramas comparativos.
24	Data augmentation controlado	Pendiente	No implementado.

6. Reflexión final

El desarrollo realizado permitió implementar el núcleo funcional del clasificador con Ridge Regression, incluyendo las partes más importantes del pipeline computacional: preprocesamiento, normalización, reducción de dimensionalidad, regularización, selección de hiperparámetro y clasificación multiclase basada en símplex regular. Además, se avanzó en la preparación de imágenes reales con una etapa de limpieza y recorte facial automatizado.

Sin embargo, al contrastar la implementación con la rúbrica, identificamos áreas pendientes. En el eje de teoría, faltan evidencias cuantitativas de multicolinealidad y una figura geométrica más clara. En programación, aún no se implementa la generación del dataset sintético, la rasterización paramétrica ni el experimento de sensibilidad al ruido. En el eje de captura y limpieza, se documentó el protocolo fotográfico, se incluyó evidencia visual del setup y se generó un archivo CSV con el registro de imágenes descartadas. Sin embargo, aún puede mejorarse el alineamiento facial mediante landmarks y la incorporación de histogramas comparativos antes y después del preprocesamiento.

Como plan de mejora, proponemos:

1. implementar alineación facial basada en landmarks,
2. incorporar histogramas comparativos antes y después del preprocesamiento,
3. integrar el experimento de sensibilidad respecto a σ,
4. implementar aumento de datos controlado,
5. añadir dataset sintético paramétrico como comparación experimental.

Consideramos que la entrega actual demuestra avance sustancial, comprensión del método y código ejecutable en las secciones declaradas como implementadas.

7. Conclusiones

Se implementó exitosamente un clasificador multiclase basado en Ridge Regression manual, con una estrategia geométrica de codificación por símplex regular. El modelo incluye normalización correcta, PCA, selección de hiperparámetro y evaluación visual y cuantitativa. Asimismo, se desarrolló una herramienta inicial para limpieza de imágenes reales.

Apéndice A — Repositorio del proyecto

Github del proyecto: https://github.com/Cuper245/modulo3-munoz